Relatório Gerencial - Apresentação Técnico-Analítico do Projeto AMPEV

A Engenharia de Dados é responsável por projetar e implementar a arquitetura *Lakehouse* da AMPEV, estruturando as camadas Bronze, Silver e Gold no *Azure Databricks*. Garante ingestão incremental confiável com *Auto Loader*, governança via *Unity Catalog* e controle histórico com *SCD Type 2* em *Delta Lake*.

Por fim, entrega dados consolidados e modelados para consumo analítico, habilitando dashboards executivos e decisões estratégicas baseadas em dados. A construção do pipeline *Lakehouse* é escalável para análise comercial para a empresa fabricante e distribuidora de bebidas AMPEV.

Problema proposto:

Os dados recebidos em formato CSV eram ingeridos sem padronização, controle de qualidade ou governança definida, resultando em inconsistências, ausência de histórico e dificuldade na rastreabilidade das informações. Não havia arquitetura estruturada para separar dados brutos, tratados e analíticos, o que comprometia a confiabilidade das análises e a tomada de decisão gerencial.

Resolução:

Criou-se uma arquitetura governada com histórico, auditoria e dashboard executivo.

Schema do fluxo de engenharia:

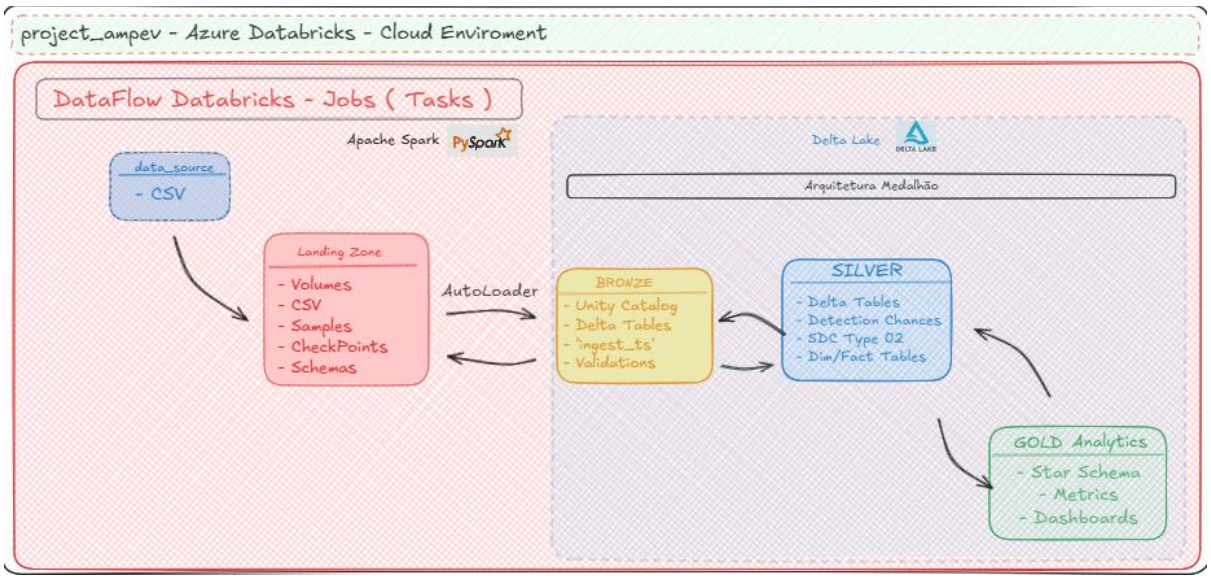

Objetivo:

O projeto tem como objetivo implementar um pipeline de ingestão incremental utilizando *Azure Databricks, Unity Catalog e Delta Lake*, seguindo a arquitetura *Medallion* (Bronze → Silver → Gold).

Estratégia implementada:

A Ingestão dos dados feita por *AutoLoader (CloudFile)* separado por entidade. Cada entidade possui:

- Pasta exclusiva
- *SchemaLocation* exclusivo
- *Checkpoint* exclusivo
- Tabela Delta exclusiva

O *AutoLoader* é um recurso do Databricks para ingestão automática de arquivos em *streaming*. Ele monitora a pasta exclusiva, também gerida pelo Databricks, Volumes, item que não pode ser versionado, onde os arquivos brutos se encontram. Por isso não é encontrado no repositório Github.

O CloudFile é o motor interno do *Auto Loader* exclusivo do Azure Databricks. Especializada para arquivos em ambientes *Cloud* (ADLS, S3, GCS) otimizado para milhões de arquivos.
Dessa forma, o *AutoLoader* detecta a pasta exclusiva Volumes, processa os arquivos novos e mantém controle dos arquivos já processados e escala automaticamente para as camadas seguintes seguindo o pipeline. Usado no projeto, exclusivamente, para a camada Bronze com ingestão dos dados brutos em modo *streaming*. Não se usa *Auto Loader* em outras camadas.

As entidades consideradas possuem estrutura e frequência de dados diferentes. Dessa forma, foram utilizadas duas pastas `Volumes` por entidades para não quebrar o *streamer*. Isso evita mistura de dados e garante isolamento.

O *schemaLocation* é o local onde o *Auto Loader* salva o *schema* das entidades e o histórico das evoluções todos gerenciados pelo *Azure Databricks*. Assim, a estrutura, alterações e controle de evolução estão no *schemaLocation*.

O *checkpoint* é onde o processador do Databricks salva os estados do *streaming - autoloader*. Assim, os arquivos gerados e processados deverão ficar salvos para

controle de evolução. Se falhar ou ocorrer problemas no processamento, o *checkpoint* salva onde parou e não reprocessa tudo. Além disso, evita a duplicidade dos dados. Depois que o *Autoloader* lê os arquivos, ele grava na tabela transacional lógica chamada Delta Lake. O Delta Lake é uma camada de armazenamento lógica transacional sobre arquivos. Transformando em um LakeHouse. Dessa forma, garantimos o ACID, versionamento e suporte a *SCD Type 2* nas dimensões, além de permitir ingestão incremental confiável na Bronze e consultas otimizadas na Gold.

Controle de histórico:

Na camada Silver é implementada a técnica SCD (*Slowly Changing Dimension Type 2*) para controle de histórico. Dessa forma, temos acesso ao histórico completo de todas as alterações que foram realizadas, garantindo rastreabilidade.

Durante a execução dessa camada, utilizamos a técnica `*window*`. A função particiona colunas, inclusive a coluna chave-primária em duas ou mais para preservar histórico. Essa abordagem permite preservar todas as versões anteriores dos registros sempre que ocorre uma alteração nos atributos de negócio, garantindo rastreabilidade completa das mudanças ao longo do tempo.

Dessa forma, a camada Silver mantém o histórico íntegro das transformações, servindo como base confiável e preparada para a modelagem dimensional que será aplicada na Camada Gold.

A camada Silver aplica a estratégia *SCD Type 2* utilizando Delta Lake, controle temporal (`*start_date*`, `*end_date*`, `*is_current*`) e `comparação via *hash*` para detecção de mudanças. Sempre que há alteração em atributos relevantes, a versão vigente é encerrada e uma nova versão é inserida, preservando o histórico completo. Essa abordagem assegura integridade temporal, auditoria de mudanças e compatibilidade com modelagem dimensional na camada Gold.

Analytics:

O *Star Schema* é um modelo de organização de dados para análise (BI) usado no projeto AMPEV. Onde existem uma tabela central de fatos e tabelas dimensão ao redor. A `CAMADA GOLD` consolida as informações através de *joins* entre `Fato e Dimensão`, aplicando regras de negócio e agregações para responder perguntas estratégicas da gerência comercial.

A tabela fato armazena os eventos de negócio mensuráveis. Cada linha representa um `PEDIDO` realizado por um estabelecimento. Ela contém métricas numéricas como `quantidade_vendida` , `valor_total` e `Preco_Unitario`. Métricas que são o coração da tabela fato.

A tabela dimensão armazena os atributos descritivos que explicam o evento da fato. Ela descreve QUEM comprou. Ela não contém métricas e sim características descritivas. Sendo assim podemos saber quem comprou, onde está localizado e como contatar, seja por e E-mail ou Telefone. A camada GOLD faz um JOIN entre as tabelas fato e dimensão permitindo responder quanto cada cliente comprou, qual cliente mais fatura e quais produtos são mais vendidos por região, por exemplo. Na camada GOLD são apresentados os registros vigentes.

Insights: Top 5 Produtos mais vendidos

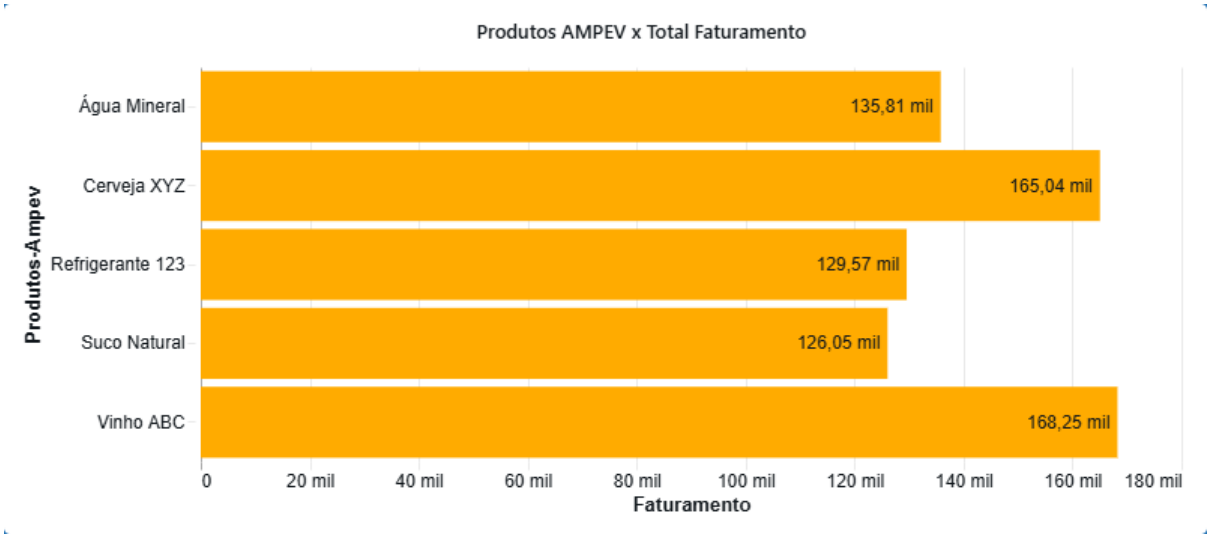

Análise de Receita por Produto

Período: Julho/2023 a Julho/2024

Durante o período analisado, observa-se clara concentração de receita nos produtos **Vinho ABC** e **Cerveja XYZ**, que lideram o faturamento e sustentam parcela relevante da performance comercial da companhia.

O **Vinho ABC** posiciona-se como principal driver de receita, evidenciando forte aderência ao mercado e potencial para expansão estratégica de distribuição e ações comerciais direcionadas. A **Cerveja XYZ**, com desempenho muito próximo ao líder, reforça a consistência do portfólio premium e demonstra estabilidade na geração de receita.

Em contrapartida, **Suco Natural** e **Refrigerante 123** apresentam menor participação relativa no faturamento consolidado, indicando possível oportunidade de revisão de estratégia seja por meio de reposicionamento de preço, campanhas promocionais, otimização de mix ou reavaliação de canais de venda.

A concentração de receita nos dois principais produtos sugere um portfólio com alta dependência de itens líderes, o que pode representar vantagem competitiva no curto prazo, mas demanda atenção quanto à diversificação e mitigação de risco no médio e longo prazo.

Performance por Volume – Top 5 Produtos - Produtos AMPEV

Período: Julho/2023 a Julho/2024

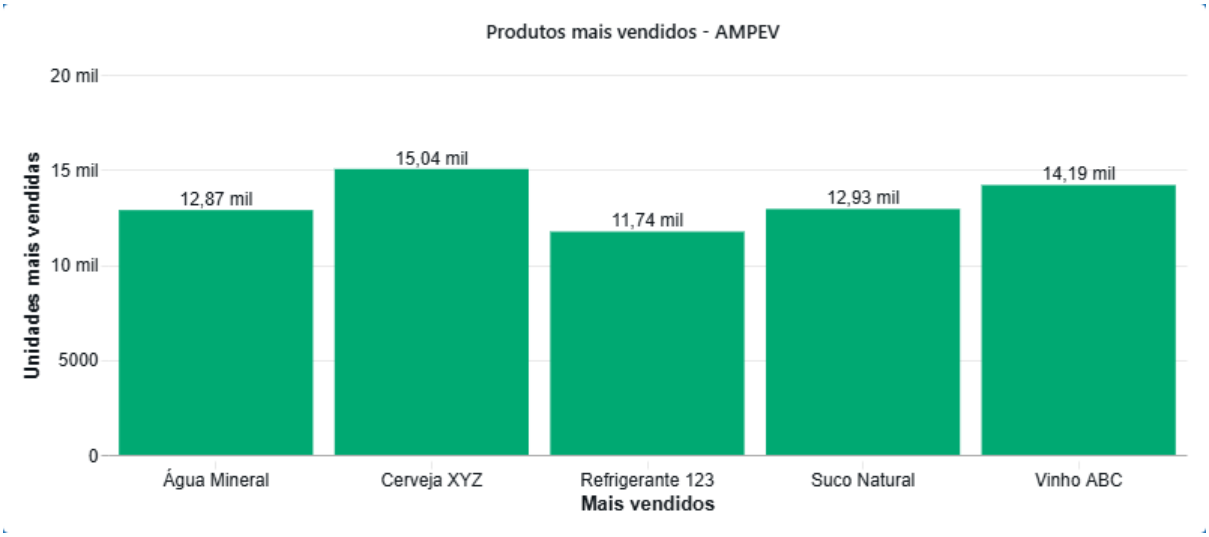

A análise de unidades comercializadas no período evidencia que a **Cerveja XYZ** lidera em volume de vendas, consolidando-se como o produto de maior giro operacional.

O **Vinho ABC**, apesar de não ocupar a primeira posição em volume, mantém forte desempenho comercial, reforçando sua relevância estratégica no portfólio. Quando analisado em conjunto com o faturamento, observa-se que o produto combina volume consistente com elevado ticket médio.

Produtos como **Água Mineral** e **Suco Natural** apresentam desempenho intermediário, sugerindo estabilidade de demanda, possivelmente associada a consumo recorrente e elasticidade menor a preço.

Já o **Refrigerante 123**, com o menor volume relativo, pode indicar necessidade de avaliação estratégica seja em posicionamento de mercado, estratégia promocional ou competitividade frente a alternativas.

Análise de Receita por Estabelecimento

Performance - Top 5 Empresas – Estabelecimentos AMPEV

Período: Julho/2023 a Julho/2024

Concentração de Receita por Cliente

Os três principais estabelecimentos representam parcela significativa da receita total, indicando foco estratégico em clientes-chave. Contudo, recomenda-se diversificação da base ativa para reduzir exposição a risco de concentração.

A análise do faturamento por estabelecimento evidencia que a **Padoca do Zé** lidera a geração de receita no período, consolidando-se como principal cliente da base analisada.

Na sequência, **Oficina Mecânica** e **Padaria do Paulo** compõem o segundo nível de contribuição, mantendo relevância significativa no volume financeiro movimentado. Os estabelecimentos **Bar e Grill** e **Bar da Esquina** apresentam desempenho semelhante, com contribuição estável e potencial de crescimento mediante ações comerciais direcionadas.

A distribuição de receita sugere **concentração moderada em poucos clientes**, o que pode representar:

- Oportunidade de fortalecimento do relacionamento com os principais parceiros
- Necessidade de mitigação de risco por dependência de receita
- Potencial de expansão nos clientes de segunda linha

Evolução de Vendas por Período

Julho/2023 a Julho/2024

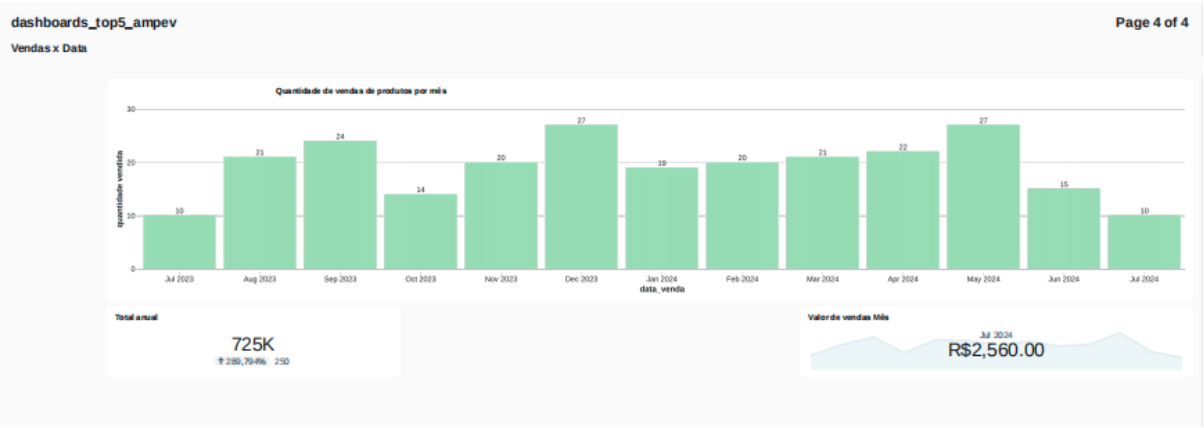

Análise Temporal de Performance

A análise mensal evidencia variação consistente no volume de vendas ao longo do período, com picos relevantes em:

- **Dezembro/2023**
- **Maio/2024**

Esses meses apresentam os maiores volumes registrados, sugerindo possíveis fatores sazonais, campanhas comerciais ou maior demanda de mercado.

Observa-se também retração em:

- **Outubro/2023**
- **Junho/2024**
- **Julho/2024**

Indicando desaceleração pontual que pode estar associada a fatores externos, sazonalidade negativa ou ajustes operacionais.

Indicadores Financeiros do Período

- **Total anual consolidado:** 725K
- **Valor de vendas – Jul/2024:** R$ 2.560,00

O consolidado anual demonstra volume financeiro relevante e estabilidade ao longo do ciclo analisado, com variações mensais dentro de um padrão controlado.

Encerramento Executivo

Análise Consolidada – Julho/2023 a Julho/2024

A análise consolidada do período evidencia um cenário de desempenho sólido, com geração consistente de receita ao longo do ciclo anual e variações mensais dentro de um padrão previsível.

Observa-se concentração estratégica do faturamento em dois produtos principais, **Vinho ABC** e **Cerveja XYZ,**que atuam como pilares da receita da operação. Enquanto a Cerveja XYZ lidera em volume de vendas, o Vinho ABC demonstra forte contribuição financeira, sugerindo posicionamento de maior valor agregado no portfólio.

Sob a perspectiva de clientes, identifica-se concentração moderada da receita em estabelecimentos-chave, com destaque para a **Padoca do Zé**, seguida por outros parceiros relevantes. Esse cenário reforça a importância de gestão estratégica do relacionamento comercial, ao mesmo tempo em que evidencia oportunidade de ampliação e diversificação da base ativa.

A análise temporal indica possíveis padrões sazonais, com picos relevantes no final de 2023 e no segundo trimestre de 2024, sugerindo influência de fatores de mercado e potencial impacto de estratégias comerciais aplicadas no período.

De forma geral, o portfólio apresenta:

- Estrutura de receita sustentada por produtos líderes
- Volume consistente ao longo do ciclo
- Concentração controlada de clientes
- Indícios de sazonalidade previsível

Direcionamentos Estratégicos

1. Fortalecer os produtos líderes, explorando expansão de mercado e fidelização.
2. Avaliar margem e rentabilidade por produto para otimização do mix.

3. Reduzir dependência relativa de clientes específicos por meio de prospecção ativa.
4. Planejar campanhas alinhadas aos períodos de maior e menor demanda.
5. Monitorar indicadores de concentração para mitigação de risco comercial.

Conclusão Final

O desempenho entre julho de 2023 e julho de 2024 demonstra operação estável, com potencial claro de crescimento sustentável. A estrutura atual oferece base sólida para expansão estratégica, desde que acompanhada de gestão ativa de portfólio, diversificação comercial e planejamento orientado por dados.